


Forecasting y Nowcasting en Series de Tiempo



Nelson Ariza Morales

CIMAT

Tell us what the future holds, so we may know that you are gods.

(Isaiah 41:23)

Se hace una revisión de la evolución histórica del Forecasting, desde modelos clásicos como ARIMA hasta enfoques modernos, y presentará el concepto de Nowcasting, que busca estimar la situación actual de variables económicas antes de la publicación oficial. Se expondrán sus fundamentos teóricos, se compararán distintos enfoques encontrados en la literatura, y se ilustrarán ejemplos prácticos con R. Finalmente, se discutirá la relevancia e impacto de estas técnicas en el análisis económico, la toma de decisiones y la formulación de políticas.

Introducción

La predicción, en sus diversas formas, ha sido una constante en la historia de la humanidad. Desde los antiguos babilonios que interpretaban los hígados de ovejas, pasando por los oráculos griegos de Delfos, hasta las primeras restricciones legales contra los pronosticadores, el deseo de anticipar el futuro ha sido tanto una fuente de fascinación como de controversia. A medida que la humanidad avanzó hacia métodos más científicos, el forecasting surgió como un enfoque sistemático para estimar el futuro basado en datos históricos y patrones identificables.

El forecasting, formalizado con el desarrollo de modelos como ARIMA y técnicas de suavizamiento exponencial, se consolidó en múltiples campos como la economía, las finanzas, el clima y la industria. Sin embargo, con el advenimiento del big data y los requerimientos de inmediatez en la toma de decisiones, emergió el nowcasting como una técnica capaz de proporcionar estimaciones casi en tiempo real. Este enfoque es particularmente útil en situaciones donde los datos oficiales están retrasados o incompletos, como en el monitoreo económico, predicciones meteorológicas y respuestas ante emergencias.

Ambos enfoques, aunque distintos en sus objetivos, comparten una base común en el análisis de series temporales y la identificación de patrones en los datos. Este trabajo aborda los siguientes puntos clave:

- Un recorrido histórico por el desarrollo de las técnicas de forecasting y nowcasting.
- Una explicación teórica de sus fundamentos, con énfasis en su evolución desde métodos lineales clásicos hasta enfoques modernos basados en aprendizaje automático.
- Una comparación entre los enfoques encontrados en la literatura, destacando sus fortalezas, limitaciones y áreas de aplicación.
- Ejemplos computacionales en R que demuestran su implementación en contextos reales.

Finalmente, un análisis del impacto y alcance de estas herramientas en la toma de decisiones estratégicas en un mundo cada vez más dependiente de datos. Con estos objetivos, el documento busca no solo proporcionar una visión integral de ambas técnicas, sino también subrayar su relevancia en un entorno dinámico donde predecir el futuro y entender el presente son esenciales para enfrentar desafíos globales.

Recorrido Histórico del Desarrollo del Forecasting y Nowcasting

La predicción del futuro, un anhelo que ha acompañado a la humanidad desde sus inicios, ha evolucionado de prácticas intuitivas y rituales hacia métodos científicos rigurosos. Este desarrollo ha sido impulsado por la necesidad de planificar, adaptarse a cambios y anticipar riesgos. En este contexto, el forecasting surgió como una herramienta esencial para predecir comportamientos futuros basándose en patrones históricos, mientras que el nowcasting ha respondido a la creciente necesidad de estimar el presente inmediato en un mundo dinámico e interconectado. Con el avance de la revolución industrial, el forecasting comenzó a consolidarse como un enfoque formal para estimar la demanda, la producción y otros fenómenos económicos. A principios del siglo XX, métodos simples como los promedios móviles y el suavizamiento exponencial se convirtieron en herramientas estándar para capturar tendencias y estacionalidades en datos históricos. Sin embargo, fue en los años 70 cuando el forecasting alcanzó un hito con la introducción de los modelos ARIMA (autorregresivos integrados de medias móviles), desarrollados por Box y Jenkins. Estos modelos permitieron modelar series temporales complejas al integrar dependencias temporales, estacionalidades y componentes aleatorios.

A medida que los métodos de forecasting evolucionaron, su aplicación se expandió a campos como la economía, el clima y la industria. Sin embargo, también surgieron desafíos inherentes al crecimiento de los datos. La calidad de los datos —afectada por ruido, valores atípicos y datos faltantes—, la capacidad de los modelos para adaptarse a cambios dinámicos y la necesidad de cálculos en tiempo real se convirtieron en obstáculos que impulsaron nuevas innovaciones.

El nowcasting emergió inicialmente en meteorología y pronto encontró aplicaciones críticas en economía. Su capacidad para estimar el presente inmediato utilizando datos de alta frecuencia, como indicadores financieros y encuestas, lo convirtió en una herramienta esencial en un mundo donde la información oficial suele tener retrasos significativos (ForecastingMethodsforTi...). Instituciones como la Reserva Federal y el Banco Central Europeo adoptaron técnicas avanzadas como filtros de Kalman y modelos factoriales dinámicos, consolidando el nowcasting como una práctica indispensable (annurev-economics-08021...).

Forecasting y nowcasting comparten fundamentos metodológicos, aunque sus horizontes temporales difieren. El primero aborda proyecciones a mediano y largo plazo, mientras el segundo se centra en el presente inmediato. Ambos enfoques se han enriquecido mutuamente: el forecasting contribuyó con modelos tradicionales como ARIMA, mientras el nowcasting integró análisis en tiempo real y adaptativos (Asurveyonforecasting...)(annurev-economics-08021...).

Fundamentos Teóricos

Para entender los modelos de predicción y nowcasting, se introduce la siguiente nomenclatura:

- Y_t : Variable de interés en el tiempo t .
- ϵ_t : Error aleatorio en el tiempo t , asumido como $\epsilon_t \sim \mathcal{N}(0, \sigma^2)$.
- ϕ_i : Coeficientes autoregresivos.
- θ_i : Coeficientes de media móvil.
- B : Operador de rezago, donde $B^k Y_t = Y_{t-k}$.
- d : Orden de diferenciación en modelos no estacionarios.
- ACF : Función de autocorrelación.
- $PACF$: Función de autocorrelación parcial.

Modelos Clásicos

Modelo Autoregresivo (AR)

El modelo AR asume que Y_t depende de sus valores pasados:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t$$

Supuestos:

1. La relación entre Y_t y sus retardos es lineal.
2. La serie es estacionaria.
3. ϵ_t es ruido blanco.

Se identifica mediante el PACF, que muestra cortes claros después del rezago p .

Modelo de Media Móvil (MA)

Representa Y_t como una combinación de errores pasados:

$$Y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q}$$

Supuestos:

- Los errores ϵ_t son ruido blanco.

Se identifica mediante el ACF, que muestra cortes en el rezago q .

Modelo ARIMA

Extiende ARMA para series no estacionarias aplicando diferenciación:

$$(1 - B)^d Y_t = ARMA(p, q)$$

Supuestos:

- d : Diferenciaciones necesarias para alcanzar estacionariedad.

Tabla 1: Análisis comparativo de las características de los modelos.

Modelo	Características	Correlograma PACF
AR(p)	1. y_t depende de sus valores pasados. 2. p se calcula usando la función PACF.	Picos hasta el retardo p , luego se reduce a cero
MA(q)	1. y_t depende del término de error que sigue un proceso de ruido blanco. 2. q se calcula usando la función ACF.	Picos que luego disminuyen a cero
ARMA(p, q)	1. ARMA = AR + MA. 2. Los valores de p y q se determinan utilizando criterios de AIC.	Picos que luego disminuyen a cero
ARIMA(p, d, q)	1. Los datos se vuelven estacionarios mediante diferenciación. 2. Se utiliza el enfoque Box-Jenkins para determinar el modelo.	Picos que luego disminuyen a cero

Modelos No Lineales

Tabla 2: Análisis comparativo de diferentes modelos.

Método	Características de los datos	Ventajas	Desventajas
Método Difuso	Pequeños datos, incompletos, valores faltantes.	Manejo de datos incompletos e inciertos.	(1) Baja precisión. (2) Débil interpretabilidad.
RNA	Grandes conjuntos de datos.	(1) Autoaprendizaje. (2) Rapidez en soluciones óptimas.	(1) Interpretabilidad débil. (2) Alto costo computacional. (3) Requiere datos masivos.
GPR	Datos de baja dimensión, pequeña muestra.	(1) Selección flexible de funciones núcleo. (2) Robustez y generalización.	(1) Difícil en datos de gran escala. (2) Sensible a parámetros y funciones núcleo.
SVM	Conjuntos pequeños y de alta dimensión.	(1) Insensibilidad a atípicos. (2) Alta generalización.	Sensible a selección de parámetros y kernel.
RNN	Dependencia corta, datos secuenciales.	Manejo de secuencias con dependencia corta.	Problemas de explosión y desaparición de gradientes.
LSTM	Dependencia larga, datos secuenciales.	(1) Manejo de largas dependencias. (2) Construcción de redes profundas.	(1) Alto costo computacional. (2) Tiempo elevado.
Transformer	Secuencias de longitud variable con dependencias complejas.	(1) Captura dependencias complejas. (2) Cálculo en paralelo.	(1) Alto costo computacional. (2) No captura relaciones a larga distancia.

Threshold Autoregressive (TAR)

Este modelo divide los datos en intervalos usando umbrales y aplica diferentes modelos lineales:

$$Y_t = \phi_j(L)Y_{t-j} + \epsilon_t, \quad \text{si } r_{j-1} \leq Y_{t-j} < r_j$$

Modelos de Volatilidad (ARCH/GARCH)

Modelan heteroscedasticidad condicional, común en series financieras:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

Modelos de Machine Learning

Artificial Neural Networks (ANN)

Utilizan redes neuronales para capturar relaciones no lineales.

RNN y LSTM

Procesan datos secuenciales, siendo LSTM especialmente útil para dependencias largas:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

Transformers

Capturan dependencias complejas mediante mecanismos de atención:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Nowcasting

Modelos de Factores Dinámicos (DFM):

Los Modelos Dinámicos Factoriales (FDM, por sus siglas en inglés) fueron introducidos por Giannone, Reichlin y Small (2008) para la predicción del Producto Interno Bruto (PIB) trimestral de Estados Unidos, aunque su concepto inicial deriva de los trabajos de Stock y Watson (1988, 1989) y de la propuesta original de Geweke (1977). Estos modelos aprovechan la representación en espacio estado para manejar múltiples series temporales y extraer factores latentes que representan la estructura subyacente común.

Consideremos el vector de n series temporales mensuales, definido como:

$$\mathbf{X}_t = \begin{pmatrix} X_{1,t} \\ X_{2,t} \\ \vdots \\ X_{n,t} \end{pmatrix}, \quad t = 1, \dots, T,$$

donde $\mathbf{X}_t \in \mathbb{R}^n$. El sistema dinámico en espacio estado se formaliza mediante las siguientes ecuaciones:

$$\mathbf{X}_t = \Lambda \mathbf{f}_t + \boldsymbol{\xi}_t, \quad \boldsymbol{\xi}_t \sim \mathcal{N}(\mathbf{0}, \Sigma_\xi),$$

donde:

- $\Lambda \in \mathbb{R}^{n \times r}$ es una matriz de ponderadores,
- $\mathbf{f}_t \in \mathbb{R}^r$ es el vector de factores latentes,
- $\boldsymbol{\xi}_t \in \mathbb{R}^n$ es un componente idiosincrático con matriz de covarianzas diagonal Σ_ξ .

$$\mathbf{f}_t = \sum_{i=1}^p A_i \mathbf{f}_{t-i} + \boldsymbol{\zeta}_t, \quad \boldsymbol{\zeta}_t = B \boldsymbol{\eta}_t, \quad \boldsymbol{\eta}_t \sim \mathcal{N}(\mathbf{0}, \mathbb{I}_q),$$

donde:

- $A_i \in \mathbb{R}^{r \times r}$ describe la dinámica autorregresiva de orden p ,
- $B \in \mathbb{R}^{r \times q}$ es una matriz de carga para el ruido,
- $\boldsymbol{\eta}_t \in \mathbb{R}^q$ es un ruido blanco multivariado.

¡En este modelo:

- \mathbf{f}_t captura las características comunes entre las series temporales mensuales.
- El componente idiosincrático $\boldsymbol{\xi}_t$ representa la variación específica de cada serie que no puede ser explicada por los factores comunes.

El uso del filtro de Kalman permite estimar los estados \mathbf{f}_t y realizar predicciones en tiempo real, resolviendo problemas como datos faltantes o series de distinta frecuencia temporal (problema de "bordes irregulares"). Estas propiedades hacen que los FDM sean herramientas esenciales en aplicaciones de nowcasting, como el seguimiento del PIB y otros indicadores económicos en tiempo real. —1

Modelos ARIMA Extendidos (ARIMA Nowcasting):

Se combinan con datos de alta frecuencia, como índices de producción industrial o encuestas de consumidores. Esto incluye los modelos "bridge equations", que realizan agregaciones mensuales para variables trimestrales.

Modelos Bayesianos:

Los modelos bayesianos incorporan la incertidumbre explícitamente y permiten actualizar las estimaciones en tiempo real a medida que llegan nuevos datos. Un ejemplo común son los modelos jerárquicos, que integran diferentes niveles de información.

Redes Neuronales y Aprendizaje Automático:

Se han empezado a incorporar modelos como redes neuronales recurrentes (RNN) y Transformers en nowcasting. Estos métodos son efectivos en la captura de relaciones no lineales y dependencias complejas entre variables, superando limitaciones de los modelos clásicos. Por ejemplo, los Transformers permiten predicciones paralelas rápidas, aunque con alto costo computacional.

Modelos Híbridos:

La combinación de métodos estadísticos tradicionales con técnicas de aprendizaje automático ha demostrado ser útil en situaciones donde los datos tienen componentes lineales y no lineales. Un modelo híbrido común incluye ARIMA-LSTM, donde ARIMA captura las tendencias lineales y LSTM maneja la no linealidad.

Aplicaciones

Estimación trimestral del PIB de México vía Forecasting

Este reporte presenta un ejemplo práctico de Nowcasting aplicado al Producto Interno Bruto (PIB) trimestral de México. El objetivo es modelar y predecir el PIB utilizando un enfoque combinado de componentes determinísticos y estocásticos, considerando factores de tendencia, estacionalidad y eventos económicos significativos.

Datos y Transformaciones

Se utilizó una serie temporal trimestral del PIB mexicano desde 1980 hasta la fecha más reciente. Las transformaciones incluyeron:

- Incorporación de variables dummy para eventos económicos clave (crisis de 1982, 1994, 2008 y 2020).
- Modelado de tendencias y estacionalidad utilizando regresión lineal.

Metodología

1. Análisis Exploratorio

Se graficaron los datos del PIB para identificar patrones de tendencia y estacionalidad.




Figura 1: Serie temporal del PIB trimestral de México.

2. Pruebas de Estacionaridad

Se aplicó la prueba de Dickey-Fuller Aumentada (ADF) a los datos del PIB y los residuales para verificar estacionaridad.

3. Modelado Determinístico

Se ajustó un modelo de regresión lineal considerando:

- **Tendencia:** Representa el crecimiento económico a largo plazo.
- **Estacionalidad:** Capturada mediante variables dummy trimestrales.
- **Eventos económicos:** Variables dummy para las crisis económicas.




Figura 2: Comparación del PIB observado vs. el modelo ajustado.

4. Modelado Estocástico

Se modelaron los residuales del modelo determinístico utilizando un modelo ARMA(1,1).




Figura 3: ACF de los residuales del modelo determinístico.

La ACF muestra un decaimiento gradual a medida que aumenta el desfase (lag). Este comportamiento indica la presencia de correlación en los residuos que no se ha capturado por el modelo determinístico.

Un decaimiento exponencial es característico de un modelo autoregresivo (AR), ya que los valores actuales dependen de los valores pasados.

Sin embargo, la ACF tiene un comportamiento mixto que también sugiere la influencia de un proceso de media móvil (MA), donde el ruido blanco previo afecta el modelo actual.




Figura 4: PACF de los residuales del modelo determinístico.

La PACF muestra un pico significativo en el primer desfase (lag 1) y disminuye rápidamente hacia cero. Este comportamiento es típico de un modelo AR(1), donde la correlación parcial es capturada únicamente en el primer término autoregresivo.

Más allá de lag 1, los valores de la PACF no son significativos, lo que sugiere que no se necesita incluir términos AR adicionales.

La combinación del decaimiento gradual de la ACF y el pico único en la PACF en lag 1 es indicativa de un modelo mixto ARMA(1,1). Este modelo captura la dependencia temporal en los residuos al incluir: Un término autoregresivo (AR(1)) para modelar la dependencia lineal

de los valores pasados. Un término de media móvil (MA(1)) para capturar el efecto del ruido blanco en los valores actuales.

5. Nowcasting y Pronóstico

Se generaron predicciones combinando los componentes determinísticos y estocásticos. Las proyecciones incluyeron intervalos de confianza para evaluar la incertidumbre.




Figura 5: Pronóstico del PIB trimestral de México.

- El modelo determinístico explicó una proporción significativa de la variabilidad del PIB, capturando la tendencia y los efectos estacionales.
- El modelo ARMA(1,1) ajustado a los residuales logró capturar la variabilidad no explicada.
- Las predicciones mostraron un buen ajuste, con un error cuadrático medio (RMSE) bajo.

Estimación trimestral del PIB de México vía Nowcasting - Simulación

Se presenta la implementación de un modelo de Nowcasting utilizando datos simulados. Se generaron indicadores económicos relacionados con el PIB trimestral. El objetivo principal es ilustrar el uso de Factores Dinámicos para la predicción inmediata del PIB en un periodo futuro.

1. Simulación de Datos

Se generaron 5 indicadores económicos (*Ventas, Producción, Empleo, Comercio y Finanzas*) a partir de una combinación de tendencias lineales, componentes oscilatorias y ruido aleatorio. Además, se simuló el PIB trimestral como una combinación lineal de dos factores latentes, con ruido añadido.

2. Visualización de los Datos Simulados

En la Figura 6 se observan los indicadores simulados, mientras que en la Figura 7 se presenta el PIB trimestral simulado.




Figura 6: Indicadores Económicos Simulados con Mayor Variabilidad.




Figura 7: PIB Trimestral Simulado.

3. Selección del Número de Factores

Para modelar los datos, se asumió la existencia de dos factores latentes. El número de factores se selecciona basándose en la proporción de varianza explicada, asegurando que estos factores capturen una fracción significativa de la variabilidad de los datos económicos. En este caso, los dos factores seleccionados explican la mayoría de la dinámica compartida entre los indicadores.

En la Figura 8, se presenta la evolución de los factores estimados, donde se puede observar cómo el *Factor 1* y el *Factor 2* capturan las tendencias predominantes de los datos simulados.

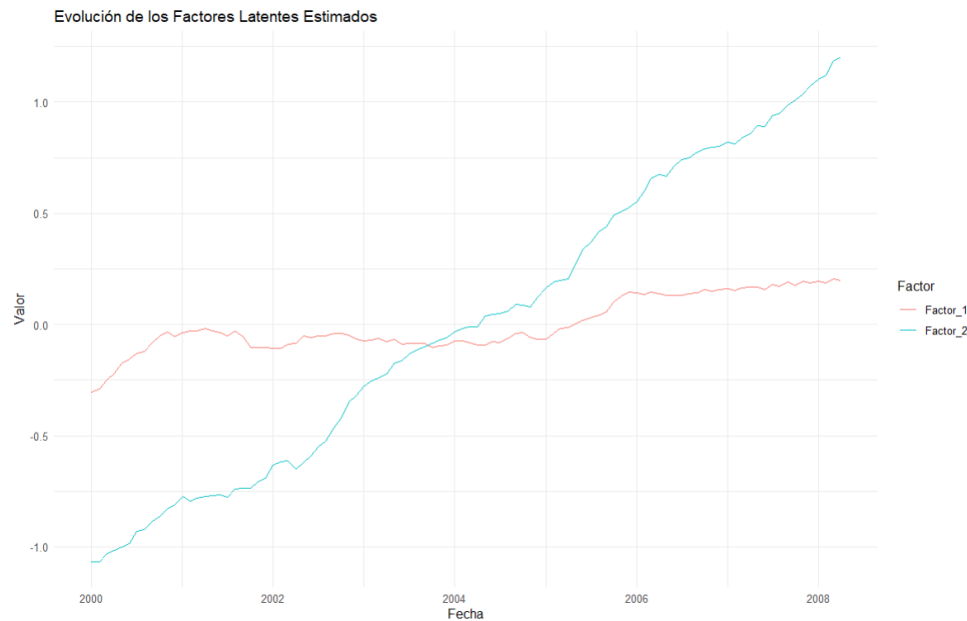


Figura 8: Evolución de los Factores Latentes Estimados.

4. Interpretación de los Factores

El *Factor 1* muestra un crecimiento continuo que se asocia con una tendencia económica a largo plazo, posiblemente relacionada con el comportamiento estructural del PIB. El *Factor 2* tiene una variación más acotada, reflejando fluctuaciones cíclicas que podrían estar relacionadas con cambios más inmediatos en los indicadores económicos.

El modelo ajustado presenta un RMSE de 2.87, lo que indica un buen desempeño considerando los datos simulados. Además, los coeficientes de los factores latentes en el modelo de regresión del PIB fueron altamente significativos ($p\text{-value} < 0.001$).

Este ejemplo demuestra cómo los Factores Dinámicos pueden capturar la información relevante de múltiples indicadores económicos y ser utilizados para predecir el PIB en tiempo real. La elección del número de factores y la interpretación de los mismos son pasos críticos para garantizar la efectividad del modelo.

Conclusión General

En este trabajo se exploraron los fundamentos teóricos, históricos y prácticos de las técnicas de Forecasting y Nowcasting en el análisis de series de tiempo. Se destacó cómo el Forecasting se enfoca en el pronóstico a futuro, mientras que el Nowcasting busca capturar estimaciones precisas y rápidas del presente o del futuro cercano, utilizando información de alta frecuencia y modelos avanzados.

Se realizó una comparativa detallada de los enfoques existentes en la literatura, evaluando sus fortalezas, limitaciones y áreas de aplicación. Esto permitió identificar que el Nowcasting, con su capacidad para integrar múltiples indicadores en tiempo real, se posiciona como una herramienta clave para la toma de decisiones en contextos dinámicos, como el monitoreo económico. Finalmente, se concluye que tanto el Forecasting como el Nowcasting tienen un impacto significativo en la toma de decisiones informadas, ya sea a largo o corto plazo. El Nowcasting, en particular, se perfila como una herramienta esencial en economías modernas donde la disponibilidad y análisis de datos en tiempo real son cruciales. Este trabajo contribuye al entendimiento

y aplicación práctica de estas técnicas, promoviendo su integración en análisis económico y de políticas públicas.

Referencias

- De Gooijer, J. G., Hyndman, R. J. (2006). 25 years of time series forecasting. *International Journal of Forecasting*, 22(3), 443–473. doi:10.1016/j.ijforecast.2006.01.001
- De Gooijer, J. G., Hyndman, R. J. (2006). 25 years of time series forecasting. *International Journal of Forecasting*, 22(3), 443–473. doi:10.1016/j.ijforecast.2006.01.001
- Mahalakshmi, G., Sridevi, S., Rajaram, S. (2016). A survey on forecasting of time series data. 2016 International Conference on Computing Technologies and Intelligent Data Engineering (ICCTIDE'16). doi:10.1109/icctide.2016.7725358
- Hyndman, R.J., Athanasopoulos, G. (2018) *Forecasting: principles and practice*, 2nd edition, OTexts: Melbourne, Australia. OTexts.com/fpp2.
- Gálvez-Soriano, Oscar de J.. (2020). Nowcasting Mexico's quarterly GDP using factor models and bridge equations. *Estudios Económicos (México, D.F.)*, 35(2), 213-265. Epub 21 de octubre de 2020. <https://doi.org/10.24201/ee.v35i2.402>